

PLAN DE RELEASE: Sistema de Detección de Fraudes (v2.0.0)

Organización: Banco Roela S.A.

Proyecto: Reemplazo de Modelo Core de Detección de Fraudes en Tarjetas de Crédito

Línea Base de Origen: fraud-model-v1.4.2 (Modelo basado en reglas estáticas y árboles de decisión clásicos)

Línea Base de Destino: fraud-model-v2.0.0 (Nuevo modelo entrenado con datasets recientes de 2026)

Entorno de destino: Entorno de producción (PROD) del Banco core

Tipo de despliegue: Despliegue Continuo (CD) mediante un Pipeline automatizado, con estrategia de transición gradual y controlada (Mitigación de riesgo mediante fases consecutivas: Shadow y Canary).

Infraestructura: El banco opera bajo una arquitectura de nube híbrida. Para la ejecución, control y monitoreo del nuevo modelo de Machine Learning, se requiere desplegar la siguiente arquitectura sobre la nube de **AWS (Amazon Web Services)**:

- Servidor de Cómputo de ML (Donde corre el modelo): Endpoint dedicado en AWS SageMaker asociado a un clúster de Amazon ECS (Elastic Container Service) bajo modalidad Fargate (Serverless), garantizando el auto-escalado ante picos transaccionales.
- API de Consulta (Para evaluar transacciones): Configurada sobre un AWS Application Load Balancer (ALB) que expone los endpoints HTTP para la mensajería del banco.
- Base de Datos de Características (Feature Store): Instancia de Amazon ElastiCache (Redis) en memoria para almacenar el historial de comportamiento inmediato del cliente con latencia menor a 50ms
- Repositorio de Modelos y Artefactos: Registro privado en Amazon ECR (Elastic Container Registry) para las imágenes Docker de producción.
- Pipeline de CI/CD (Automatización): Orquestado mediante GitHub Actions para la integración y AWS CodeDeploy para el despliegue físico.
- Sistema de Monitoreo, Alertas y Logs de Auditoría: Centralizado en AWS CloudWatch con tableros de control específicos para el negocio financiero
- Mecanismo de Retorno Automático: Configuración de políticas de desvío de tráfico por peso de red (Weight-based routing) en el balanceador de carga para actuar como interruptor de emergencia (Kill Switch).

Artefacto: Imagen de contenedor Docker registrada en Amazon ECR con el Tag **fraud-model-v2.0.0**. Esta imagen contiene el código del microservicio en Python (Flask/FastAPI), los pesos del modelo serializados (modelo_fraude_2026_v2.bin), y el pipeline de transformación de datos (Pandas/Scikit-Learn).

Version anterior: Imagen de contenedor Docker registrada como **fraud-model-v1.4.2**. Al ser un modelo monolítico anterior, los servidores viejos se mantendrán encendidos y en ejecución (calientes) durante todo el proceso, listos para recibir el 100% del tráfico de inmediato si es necesario.

Como se realiza el despliegue e instalación del artefacto:

• Fase de Despliegue:

1. El Pipeline de CI/CD (GitHub Actions) compila la imagen Docker fraud-model-v2.0.0, ejecuta las pruebas unitarias y la sube al registro privado (ECR).
2. AWS CodeDeploy toma la imagen desde el repositorio ECR y gatilla la creación de las nuevas tareas en Amazon ECS dentro del entorno de producción.

• Fase de Instalación:

3. Al inicializarse las tareas en Amazon ECS, el contenedor Docker ejecuta internamente el servidor productivo de Python, instalando y cargando los pesos y parámetros del modelo de Machine Learning en la memoria RAM de las instancias AWS Fargate, quedando el microservicio en estado pasivo/sombra, listo para operar.

Dependencias:

- **Core del Sistema de Tarjetas de Crédito:** API de autorización bancaria que envía las peticiones de transacciones.
- **Base de Datos de Características (Feature Store - Redis):** Repositorio en memoria desde donde el modelo consume el historial transaccional reciente del cliente en tiempo real.
- **Base de Datos de Clientes (NoSQL):** Para validar estados de cuentas, límites de crédito y datos demográficos del usuario durante el scoring.
- **API Interna de Scoring / Enrutamiento:** Sistema intermedio que orquesta si la transacción se procesa por el modelo viejo, por el nuevo, o por ambos.
- **Librerías del Motor de Inferencia (Python):** Dependencias estrictas de Código
 - **xgboost o scikit-learn** (para ejecutar el algoritmo matemático del modelo).
 - **fastapi o flask con unicorn** (para levantar el servidor web productivo).
 - **redis-py** (para la conexión con la Feature Store).

Prerrequisitos antes del despliegue:

- **Validación de Datos:** Modelo entrenado y validado con datasets recientes de 2026, habiendo superado con éxito las pruebas de regresión con datos históricos.
- **Pruebas de Integración:** Pruebas de conectividad técnica aprobadas entre el entorno de QA y el sistema simulador de tarjetas.
- **Aprobaciones Formales:** Firma digital y aprobación del plan por parte de la Gerencia de Riesgo y Fraude
- **Configuración de observabilidad:** Alertas de desvío y tableros de control de CloudWatch configurados y activos en el entorno de destino.
- **Disponibilidad de Rollback:** Asegurar que la Línea Base anterior (fraud-model-v1.4.2) esté en ejecución activa y con capacidad de absorber el 100% del tráfico ante una emergencia.

Horario de despliegue: Martes de **02:00 AM a 04:00 AM** (Hora local de Argentina). Se elije este horario ya que representa la ventana de menor actividad transaccional del banco en la semana. Al realizarse durante la madrugada profunda, el volumen de compras legítimas es mínimo, lo que mitiga drásticamente el impacto en el negocio y en la experiencia de los clientes si el sistema experimenta microcortes o anomalías imprevistas durante la configuración del balanceador.

Forma de despliegue (técnica): Despliegue automatizado basado en Contenedores Docker orquestados por Amazon ECS, utilizando GitHub Actions y AWS CodeDeploy como motores de orquestación, y Traffic Mirroring a nivel del Application Load Balancer para clonar el tráfico de red.

Estrategia para reducir riesgos: Debido al riesgo crítico que representa para el negocio, utilizaremos la unión de dos técnicas, Fase Shadow + Transición Canaria Progresiva, dividiendo el despliegue en tres fases:

- **Fase 1 (Shadow 48hs):** El nuevo modelo procesa el 100% del tráfico duplicado. Sus decisiones de "Aprobado/Fraude" se guardan en la base de datos de logs, pero no bloquean ninguna tarjeta. Pasadas las 48 horas, se comparan sus decisiones con las del modelo viejo y los fraudes reales reportados para calcular la tasa exacta de falsos positivos en producción.
- **Fase 2 (Canario progresivo):** Si la fase sombra es exitosa, se corta la duplicación y se activa el tráfico real en vivo de manera escalonada:
 - Día 1: El 1% del tráfico real va al modelo nuevo; el 99% restante va al viejo.
 - Día 2: Se escala al 10% del tráfico real.
 - Día 3: Se escala al 50%.
 - Día 4: Se escala al 100% del tráfico real.
- **Fase 3 (Cierre):** Una vez escalado el 100% del tráfico real al nuevo modelo, se apaga el modelo anterior v1.4.2. Pero siempre dejándolo disponible para rollback en caso de que las métricas superen límites aceptables

Monitoreo:

- **Disponibilidad del servicio:** Medición del uptime general de los endpoints del nuevo modelo en AWS ECS. Umbral de alerta: 99%
- **Tiempo de respuesta del modelo (Latencia):** Tiempo que le toma al modelo procesar el payload y devolver el score de fraude. Umbral de alerta: Promedio 50ms, degradación automática (bypass al modelo anterior) si supera los 80ms
- **En fase Shadow**
 - **Comparación de Scores en Paralelo:** Se analiza en tiempo real cómo deciden ambos modelos ante el mismo tráfico.
 - **Cálculo Técnico de Falsos Positivos:** Identificación de transacciones que el modelo nuevo habría bloqueado por sospecha, pero que el modelo viejo aprobó y resultaron ser compras legítimas de los clientes.
 - **Cálculo Técnico de Falsos Negativos:** Identificación de transacciones que el modelo nuevo habría dejado pasar (aprobado), pero que el modelo viejo detectó como fraude o que el cliente denunció posteriormente como estafa.
- **En fase canaria**
 - **Cantidad de fraudes detectados:** Volumen total de estafas reales mitigadas y frenadas en el checkout por el nuevo modelo.
 - **Cantidad de transacciones bloqueadas:** Métrica de control del volumen total de rechazos. Si esta curva se despega abruptamente de la media histórica del banco, se asume una anomalía.
 - **Reclamos de clientes:** Integración de telemetría con el sistema del Call Center. Monitoreo de llamadas entrantes por tarjetas inactivas o bloqueos erróneos en el instante de la compra. Una subida del **2%** en estos reclamos dispara de forma automática el plan de contingencia (Rollback).

Pruebas post-despliegue:

- **Smoke Tests de Conectividad:** 50 transacciones simuladas (25 legítimas conocidas y 25 patrones de fraude conocidos) enviadas directamente al endpoint del nuevo modelo para verificar que responda con HTTP 200, los logs en CloudWatch no arrojen excepciones de código y devuelva el score de fraude en menos de 50ms para verificar la latencia
- **Monitoreo de Tiempos de Respuesta:** Verificar mediante un script de carga liviano que el percentil 95 de la latencia del modelo se mantenga estrictamente por debajo de los 50ms bajo una simulación de 10 transacciones concurrentes por segundo. Esto asegura que el modelo no va a generar cuellos de botella en la red del banco.
- **Verificación de Formato y Estándares:** Control inmediato en AWS CloudWatch para corroborar que los payloads de las tarjetas se estén parseando correctamente sin generar errores de formato JSON o excepciones críticas de tipado
- **Enmascaramiento de Datos Prudentes:** Validar en los logs que los datos sensibles del cliente (como el PAN/número de tarjeta o el código de seguridad CVV) estén encriptados o enmascarados, cumpliendo de forma estricta con las normativas de seguridad bancaria.

Comunicaciones y aprobaciones:

- **Antes del despliegue:** Se notifica con 48 horas de anticipación al Gerente de Operaciones, al equipo de Infraestructura, Seguridad Informática y al Director del Call Center (para que refuercen la guardia ante posibles quejas).
- **Quien debe aprobar el despliegue:** El despliegue deberá ser aprobado por el Product Manager del área de Riesgo/Fraude dando la aprobación de negocio de que el modelo cumple con las expectativas financieras, por otro lado, también deberá ser aprobado por el Líder QA que dará la aprobación técnica del modelo.
- **Después del despliegue:** Se envía el reporte técnico final a la Gerencia Ejecutiva confirmando el éxito del despliegue y la desactivación del código legacy.

Plan de rollback / contingencia:

1. Primero se realizará una desconexión automatizada, donde el ALB cambia de forma automática el peso del enrutamiento, asignando el 100% del tráfico al modelo anterior (fraud-model-v1.4.2). Con un tiempo de respuesta estimado menor a 5 segundos
2. El equipo de operaciones deberá verificar que el sistema vuelva a operar normalmente sobre el modelo anterior
3. Se aislará el entorno del nuevo modelo (v2.0.0) cortando su acceso al tráfico productivo, pero manteniéndolo encendido en un entorno controlado para posibilitar la extracción de logs y métricas que causaron el fallo.
4. Se deberá notificar a los equipos involucrados mediante un correo automático notificando que se ejecutó un Rollback preventivo y que la operación de tarjetas de crédito se encuentra funcionando con total normalidad bajo el modelo seguro anterior.
5. El equipo de Científicos de Datos y DevOps realizará un análisis de causa raíz sobre los logs aislados para identificar el origen del desvío
6. Corrección del modelo o de sus variables de configuración en el entorno de desarrollo, iniciando un nuevo ciclo de integración continua para planificar una nueva ventana de release.